

DeepSeek-V4-Pro

API 接口文档

版本: v1.0

日期: 2026-05-08

提供方: 鸿钧计算

深圳鸿钧计算科技有限公司

目录

1. 模型概述	3
2. 接入信息	4
2.1 接口地址	4
2.2 鉴权方式	4
2.3 请求规范	4
3. 接口详细说明	5
3.1 聊天补全 — Chat Completions	5
3.1.1 基础参数	5
3.1.2 DeepSeek-V4-Pro 特有参数	6
3.1.3 SGLang 扩展采样参数（通过 <code>extra_body</code> 传入）	6
3.2 <code>messages</code> 消息格式	6
3.3 响应格式	7
3.3.1 非流式响应	7
3.3.2 响应字段说明	7
3.3.3 流式响应（SSE）	8
3.4 JSON 输出模式	9
3.5 工具调用（Function Calling）	9
3.5.1 <code>tools</code> 参数格式	9
3.5.2 <code>tool_choice</code> 属性	10
3.5.3 工具调用响应示例	10
3.5.4 工具结果回传	10
4. 调用示例	11
4.1 普通对话（关闭推理）	11
4.2 深度推理模式（Think High）	12
4.3 流式输出	13
4.4 工具调用	14
4.5 结构化 JSON 输出（ <code>json_schema</code> ）	14
4.6 Python SDK 调用示例	16
4.7 多轮对话示例	17
5. 注意事项	18
6. 错误码说明	19
附录：模型属性列表	20

1. 模型概述

DeepSeek-V4-Pro 是 DeepSeek AI 发布的旗舰级大语言模型，采用稀疏混合专家（MoE）架构，结合混合注意力机制（CSA/HCA），总参数量 1.6T，每个 token 激活约 49B 参数，最大支持 128K 上下文长度。

核心能力：

- 深度推理与思维链（Chain-of-Thought），通过 reasoning_content 字段返回，支持三档推理强度（Non-think / Think High / Think Max）
- 原生工具调用（Tool Calling）与并行工具调用
- 结构化 JSON 输出（支持 json_object 和 json_schema 模式）
- 代码生成与分析、数学推理与复杂问题求解
- 支持中文、英文及多种语言

2. 接入信息

2.1 接口地址

类型	地址
统一入口（推荐）	https://apiai.sztu.edu.cn/v1/chat/completions

2.2 鉴权方式

在请求 Header 中携带 API Key:

Authorization: Bearer YOUR_API_KEY

2.3 请求规范

项目	说明
请求方法	POST
Content-Type	application/json
字符编码	UTF-8
超时设置	连接 60s，读写 600s（长文本请适当调高）

3. 接口详细说明

3.1 聊天补全 — Chat Completions

POST <https://api.ai.sztu.edu.cn/v1/chat/completions>

请求 Body 为 JSON 格式，字段说明如下。

3.1.1 基础参数

参数名	类型	是否必填	默认值	说明
model	string	是	—	模型名称，固定传入 <code>deepseek-v4-pro</code>
messages	array	是	—	对话消息列表，详见 3.2 节
temperature	float	否	1.0	采样温度，范围 <code>[0, 2]</code> 。推理模式下被忽略
top_p	float	否	1.0	核采样，范围 <code>(0, 1]</code> 。推理模式下被忽略
max_tokens	int	否	—	最大生成 token 数（含思维链）。推理复杂问题建议 ≥ 2000
stream	bool	否	false	是否启用流式输出（SSE）
stream_options	object	否	null	流式统计配置， <code>{"include_usage": true}</code> 在最后一个 chunk 返回 usage
stop	string/array	否	—	停止序列，触发后立即停止生成，最多 16 个
frequency_penalty	float	否	0.0	频率惩罚，范围 <code>[-2.0, 2.0]</code> 。推理模式下被忽略
presence_penalty	float	否	0.0	存在惩罚，范围 <code>[-2.0, 2.0]</code> 。推理模式下被忽略
logprobs	bool	否	false	是否返回 token 级对数概率。推理模式下不可用
top_logprobs	int	否	—	返回 top-k token 的 logprobs，范围 <code>[0, 20]</code> ，需配合 <code>logprobs=true</code>
response_format	object	否	—	输出格式控制，详见 3.4 节
tools	array	否	—	工具/函数定义列表，详见 3.5 节
tool_choice	string/object	否	auto	工具选择策略，详见 3.5 节

3.1.2 DeepSeek-V4-Pro 特有参数

以下参数通过请求 Body 的 chat_template_kwargs 字段传入。使用 OpenAI SDK 时，请通过 extra_body={"chat_template_kwargs": {...}} 传递。

参数名	类型	可选值	默认值	说明
chat_template_kwargs.thinking	bool	true / false	true	推理模式开关。 true 开启思维链推理； false 关闭推理直接输出正文。不传时默认 true
chat_template_kwargs.reasoning_effort	string	"high" / "max"	"high"	推理强度档位，仅 thinking=true 时生效。 high : 标准逻辑分析； max : 全力推理（建议 max_tokens ≥ 4000 ）

注意：thinking 默认开启。非推理场景（普通对话、翻译等）建议显式传入 {"thinking": false} 关闭，可显著降低响应延迟并减少 token 消耗。

3.1.3 SGLang 扩展采样参数（通过 extra_body 传入）

参数名	类型	默认值	说明
top_k	int	-1（关闭）	Top-K 采样，-1 表示禁用
min_p	float	0.0	最小概率阈值采样
repetition_penalty	float	1.0	重复惩罚，>1 时抑制重复输出，推荐范围 1.0–1.2

3.2 messages 消息格式

messages 为对象数组，每个对象包含以下字段：

字段	类型	必填	说明
role	string	是	system / user / assistant / tool
content	string	视情况	消息内容；工具调用时 assistant 可为 null
reasoning_content	string	否	多轮对话中可回传上轮思维链内容（建议不回传，详见 5. 注意事项）
tool_calls	array	否	assistant 消息中的工具调用列表
tool_call_id	string	否	tool 角色消息中对应的工具调用 ID

示例：

```
[
  { "role": "system", "content": "你是一个有帮助的 AI 助手" },
  { "role": "user", "content": "请介绍一下你自己" }
]
```

3.3 响应格式

3.3.1 非流式响应

```
{
  "id": "chatcmpl-a1b2c3d4e5f6",
  "object": "chat.completion",
  "created": 1746700800,
  "model": "deepseek-v4-pro",
  "choices": [{
    "index": 0,
    "message": {
      "role": "assistant",
      "content": "最终回答内容",
      "reasoning_content": "思维链推理过程 (thinking=true 时返回, 否则为 null)",
      "tool_calls": []
    },
    "finish_reason": "stop"
  }],
  "usage": {
    "prompt_tokens": 12,
    "completion_tokens": 350,
    "total_tokens": 362,
    "completion_tokens_details": { "reasoning_tokens": 310 }
  }
}
```

3.3.2 响应字段说明

字段	类型	说明
id	string	请求唯一 ID
object	string	固定为 chat.completion
created	int	Unix 时间戳（秒）
model	string	实际使用的模型名称
choices[].message.role	string	固定为 assistant
choices[].message.content	string	最终回答内容；工具调用时为 null
choices[].message.reasoning_content	string	思维链推理过程。thinking=true 时返回，否则为 null
choices[].message.tool_calls	array	工具调用列表，无调用时为空数组
choices[].finish_reason	string	stop / length / tool_calls / content_filter
usage.prompt_tokens	int	输入 token 数
usage.completion_tokens	int	生成 token 总数（含思维链部分）
usage.total_tokens	int	总 token 数（prompt + completion）

字段	类型	说明
completion_tokens_details.reasoning_tokens	int	思维链消耗的 token 数（completion_tokens 的子集）

3.3.3 流式响应（SSE）

设置 stream: true 后，服务端以 Server-Sent Events 格式推送数据，每行格式为 data: {...}，结束标志为 data: [DONE]。

```
# 首个 chunk (role 声明)
data: {"id":"chatcmpl-xxx","object":"chat.completion.chunk","model":"deepseek-v4-pro",

"choices":[{"index":0,"delta":{"role":"assistant","content":""},"finish_reason":null}]}

# 思维链阶段 (delta.reasoning_content, 先于 content 流出)
data: {"id":"chatcmpl-xxx","object":"chat.completion.chunk","model":"deepseek-v4-pro",

      "choices":[{"index":0,"delta":{"reasoning_content":" 推 理 过 程 片 段"},"finish_reason":null}]}

# 正文阶段 (delta.content)
data: {"id":"chatcmpl-xxx","object":"chat.completion.chunk","model":"deepseek-v4-pro",

      "choices":[{"index":0,"delta":{"content":" 生 成 内 容 片 段"},"finish_reason":null}]}

# 结束 chunk
data: {"id":"chatcmpl-xxx","object":"chat.completion.chunk","model":"deepseek-v4-pro",

      "choices":[{"index":0,"delta":{},"finish_reason":"stop"}]}

data: [DONE]
```

注意：思维链内容（delta.reasoning_content）先于正文（delta.content）流出，两者顺序传输不重叠。如需在流式获取 usage，可传入 stream_options: {"include_usage": true}，最后一个 chunk 将携带完整 usage 统计。

3.4 JSON 输出模式

通过 `response_format` 参数控制输出格式:

参数值	说明
<code>{"type": "text"}</code>	默认, 纯文本输出
<code>{"type": "json_object"}</code>	强制输出合法 JSON 对象。System Prompt 中需同时提示返回 JSON, 否则可能输出异常
<code>{"type": "json_schema", "json_schema": {...}}</code>	按指定 JSON Schema 约束输出, 支持 <code>strict: true</code> 严格模式。Schema 中所有 object 须将属性标为 <code>required</code> 且设 <code>additionalProperties: false</code>

json_schema 示例:

```
"response_format": {
  "type": "json_schema",
  "json_schema": {
    "name": "person",
    "strict": true,
    "schema": {
      "type": "object",
      "properties": {
        "name": { "type": "string" },
        "age": { "type": "integer" },
        "city": { "type": "string" }
      },
      "required": ["name", "age", "city"],
      "additionalProperties": false
    }
  }
}
```

3.5 工具调用 (Function Calling)

DeepSeek-V4-Pro 原生支持并行工具调用, 单次可返回多个工具调用结果。

3.5.1 tools 参数格式

```
"tools": [
  {
    "type": "function",
    "function": {
      "name": "get_weather",
      "description": "获取指定城市的天气信息",
      "parameters": {
        "type": "object",
        "properties": {
          "city": { "type": "string", "description": "城市名称" }
        }
      }
    }
  },
  ...
]
```

```
        "required": ["city"]
    }
}
]
```

3.5.2 tool_choice 属性

取值	说明
"auto"	模型自动决定是否调用工具（默认）
"none"	禁止调用任何工具
"required"	强制必须调用至少一个工具
{"type":"function","function":{"name":"xxx"}}	强制调用指定名称的函数

3.5.3 工具调用响应示例

```
{
  "choices": [{
    "index": 0,
    "message": {
      "role": "assistant",
      "content": null,
      "reasoning_content": null,
      "tool_calls": [{
        "id": "chatcmpl-tool-86d187278aa1521e",
        "type": "function",
        "function": {
          "name": "get_weather",
          "arguments": "{\"city\": \"深圳\"}"
        }
      }
    ],
    "finish_reason": "tool_calls"
  }
]}
```

注意：function.arguments 为 JSON 编码的字符串，非 dict 对象，使用前需先进行 JSON 解析。

3.5.4 工具结果回传

获取工具执行结果后，将结果作为 tool 角色消息回传给模型：

```
{
  "role": "tool",
  "tool_call_id": "chatcmpl-tool-86d187278aa1521e",
  "content": "{\"temperature\": 28, \"condition\": \"sunny\"}"
}
```

4. 调用示例

4.1 普通对话（关闭推理）

请求：

```
curl -X POST https://api.ai.sztu.edu.cn/v1/chat/completions \
-H "Content-Type: application/json" \
-H "Authorization: Bearer YOUR_API_KEY" \
-d '{
  "model": "deepseek-v4-pro",
  "messages": [{"role": "user", "content": "你好，用一句话介绍你自己"}],
  "max_tokens": 100,
  "chat_template_kwargs": {"thinking": false}
}'
```

响应：

```
{
  "id": "chatcmpl-964b85dd13387c64",
  "object": "chat.completion",
  "created": 1746700800,
  "model": "deepseek-v4-pro",
  "choices": [{
    "index": 0,
    "message": {
      "role": "assistant",
      "content": "我是 DeepSeek-V4-Pro，一个强大的 AI 助手，致力于为你提供高效准确的解",
      "reasoning_content": null,
      "tool_calls": []
    },
    "finish_reason": "stop"
  }],
  "usage": {
    "prompt_tokens": 11,
    "completion_tokens": 22,
    "total_tokens": 33,
    "completion_tokens_details": {"reasoning_tokens": 0}
  }
}
```

4.2 深度推理模式 (Think High)

请求:

```
curl -X POST https://api.ai.sztu.edu.cn/v1/chat/completions \
-H "Content-Type: application/json" \
-H "Authorization: Bearer YOUR_API_KEY" \
-d '{
  "model": "deepseek-v4-pro",
  "messages": [{"role": "user", "content": "9.11 和 9.8 哪个大? "}],
  "max_tokens": 2000,
  "chat_template_kwargs": {"thinking": true, "reasoning_effort": "high"}
}'
```

响应:

```
{
  "id": "chatcmpl-ad8344d9643973d6",
  "object": "chat.completion",
  "created": 1746700800,
  "model": "deepseek-v4-pro",
  "choices": [{
    "index": 0,
    "message": {
      "role": "assistant",
      "content": "9.8 更大。整数部分相同，十分位 8 > 1，所以 9.8 > 9.11。",
      "reasoning_content": "用户在比较 9.11 和 9.8 的大小。这是一个经典的小数比较问题...",
      "tool_calls": []
    },
    "finish_reason": "stop"
  }],
  "usage": {
    "prompt_tokens": 15,
    "completion_tokens": 320,
    "total_tokens": 335,
    "completion_tokens_details": {"reasoning_tokens": 295}
  }
}
```

4.3 流式输出

请求：

```
curl -N -X POST https://apiai.sztu.edu.cn/v1/chat/completions \
-H "Content-Type: application/json" \
-H "Authorization: Bearer YOUR_API_KEY" \
-d '{
  "model": "deepseek-v4-pro",
  "messages": [{"role": "user", "content": "写一首关于深圳的短诗"}],
  "max_tokens": 200,
  "stream": true,
  "chat_template_kwargs": {"thinking": false}
}'
```

响应（SSE 片段）：

```
data: {"id":"chatcmpl-xxx","object":"chat.completion.chunk","model":"deepseek-
v4-pro",

"choices":[{"index":0,"delta":{"role":"assistant","content":""},"finish_reason
":null}]}

data: {"id":"chatcmpl-xxx","object":"chat.completion.chunk","model":"deepseek-
v4-pro",
      "choices":[{"index":0,"delta":{"content":"风"},"finish_reason":null}]}

... （省略中间 chunks）

data: {"id":"chatcmpl-xxx","object":"chat.completion.chunk","model":"deepseek-
v4-pro",
      "choices":[{"index":0,"delta":{},"finish_reason":"stop"}]}

data: [DONE]
```

4.4 工具调用

请求:

```
curl -X POST https://api.ai.sztu.edu.cn/v1/chat/completions \
-H "Content-Type: application/json" \
-H "Authorization: Bearer YOUR_API_KEY" \
-d '{
  "model": "deepseek-v4-pro",
  "messages": [{"role": "user", "content": "今天深圳天气怎样? "}],
  "tools": [{
    "type": "function",
    "function": {
      "name": "get_weather",
      "description": "获取城市当前天气",
      "parameters": {
        "type": "object",
        "properties": {"city": {"type": "string"}},
        "required": ["city"]
      }
    }
  ]},
  "tool_choice": "auto",
  "chat_template_kwargs": {"thinking": false}
}'
```

4.5 结构化 JSON 输出 (json_schema)

请求:

```
curl -X POST https://api.ai.sztu.edu.cn/v1/chat/completions \
-H "Content-Type: application/json" \
-H "Authorization: Bearer YOUR_API_KEY" \
-d '{
  "model": "deepseek-v4-pro",
  "messages": [{"role": "user", "content": "生成一个个人信息"}],
  "response_format": {
    "type": "json_schema",
    "json_schema": {
      "name": "person",
      "strict": true,
      "schema": {
        "type": "object",
        "properties": {
          "name": {"type": "string"},
          "age": {"type": "integer"},
          "city": {"type": "string"}
        },
        "required": ["name", "age", "city"],
      }
    }
  }
}'
```

```
        "additionalProperties": false
      }
    },
    "chat_template_kwargs": {"thinking": false}
  }'
```

响应:

```
{
  "id": "chatcmpl-873ac290b9b9a184",
  "object": "chat.completion",
  "created": 1746700800,
  "model": "deepseek-v4-pro",
  "choices": [{
    "index": 0,
    "message": {
      "role": "assistant",
      "content": "{ \"name\": \"林野\", \"age\": 24, \"city\": \"深圳\" }",
      "reasoning_content": null,
      "tool_calls": []
    },
    "finish_reason": "stop"
  }],
  "usage": {
    "prompt_tokens": 9,
    "completion_tokens": 27,
    "total_tokens": 36,
    "completion_tokens_details": {"reasoning_tokens": 0}
  }
}
```

4.6 Python SDK 调用示例

```
from openai import OpenAI

client = OpenAI(
    api_key="YOUR_API_KEY",
    base_url="https://api.ai.sztu.edu.cn/v1"
)

# 普通对话（关闭推理）
resp = client.chat.completions.create(
    model="deepseek-v4-pro",
    messages=[
        {"role": "system", "content": "你是一个有帮助的 AI 助手。"},
        {"role": "user", "content": "你好"},
    ],
    max_tokens=512,
    extra_body={"chat_template_kwargs": {"thinking": False}}
)
print(resp.choices[0].message.content)

# 深度推理模式（获取思维链）
resp = client.chat.completions.create(
    model="deepseek-v4-pro",
    messages=[{"role": "user", "content": "9.11 和 9.8 哪个大? "}],
    max_tokens=2000,
    extra_body={"chat_template_kwargs": {"thinking": True, "reasoning_effort": "high"}}
)
print("思维链: ", resp.choices[0].message.reasoning_content)
print("回答: ", resp.choices[0].message.content)
```


4.7 多轮对话示例

以下示例展示如何正确构造多轮对话的 `messages` 列表:

```
from openai import OpenAI

client = OpenAI(api_key="YOUR_API_KEY",
base_url="https://api.ai.sztu.edu.cn/v1")

messages = [{"role": "system", "content": "你是一个有帮助的 AI 助手。"}]

# 第一轮
messages.append({"role": "user", "content": "深圳有哪些著名景点? "})
resp = client.chat.completions.create(
    model="deepseek-v4-pro",
    messages=messages,
    max_tokens=500,
    extra_body={"chat_template_kwargs": {"thinking": False}}
)
reply = resp.choices[0].message.content
print("第一轮: ", reply)

# 回传时不包含 reasoning_content
messages.append({"role": "assistant", "content": reply})

# 第二轮
messages.append({"role": "user", "content": "其中哪个最适合带小孩去? "})
resp = client.chat.completions.create(
    model="deepseek-v4-pro",
    messages=messages,
    max_tokens=500,
    extra_body={"chat_template_kwargs": {"thinking": False}}
)
print("第二轮: ", resp.choices[0].message.content)
```

5. 注意事项

- 推理模式默认开启（`thinking=true`）。非推理场景建议显式传入 `{"thinking": false}` 关闭，可大幅降低延迟并节省 token。
- 开启推理模式时，`temperature`、`top_p`、`presence_penalty`、`frequency_penalty` 参数将被静默忽略，不会触发报错。
- `max_tokens` 同时限制思维链与正文的总生成长度。推理复杂问题建议 ≥ 2000 ；Think Max 模式建议 ≥ 4000 。
- 当前服务最大上下文长度为 131072 tokens（128K），超出将返回错误。
- 多轮对话中，建议不将上轮 `assistant` 消息的 `reasoning_content` 字段回传，以避免不必要的 token 消耗和注意力偏移。
- 工具调用时，`function.arguments` 为 JSON 编码的字符串，非 `dict` 对象，使用前需先进行 JSON 解析。
- `tool` 角色的 `content` 字段必须为字符串类型，不可传入数组或对象。
- 流式模式下，思维链通过 `delta.reasoning_content` 流出，正文通过 `delta.content` 流出，顺序传输不重叠。
- 使用 `json_schema` 模式时，Schema 中所有 `object` 类型须将属性标为 `required` 且设 `additionalProperties: false`，否则可能导致输出不符合预期。

6. 错误码说明

HTTP 状态码	错误类型	说明及处理建议
400	Bad Request	请求参数格式错误，检查 JSON 格式及必填字段
401	Unauthorized	API Key 无效或未传入，检查 Authorization 头部
422	Unprocessable Entity	参数值超出范围或 model 字段不匹配，检查参数取值
429	Too Many Requests	请求频率超限，建议添加重试逻辑（推荐指数退避）
500	Internal Server Error	服务端内部错误，可重试，持续出现请联系技术支持
503	Service Unavailable	服务暂时不可用，通常为短暂过载，稍后重试

错误响应体格式：

```
{
  "object": "error",
  "message": "Model not found: deepseek-v4",
  "type": "invalid_request_error",
  "code": 400
}
```

附录：模型属性列表

属性	值
模型名称	deepseek-v4-pro
总参数量	1.6T
每 token 激活参数	~49B
最大上下文	131072 tokens（128K）
默认 temperature	1.0
默认 top_p	1.0
支持语言	中文、英文及多种语言
支持工具调用	是（支持并行调用）
推理模式	三档：Non-think / Think High / Think Max
支持 JSON 输出	是（json_object / json_schema 模式）
支持流式输出	是（SSE）
支持图片输入	否（纯文本模型）
架构	稀疏混合专家（MoE）+ 混合注意力（CSA/HCA）